

张翔宇

✉ neuzxy@126.com · ☎ (+86) 188-1173-1628 · [GitHub](#)

🎓 教育背景

北京大学 2014.09 – 2017.07

工学硕士 保送软件工程一级学科学术型硕士

东北大学 2010.09 – 2014.07

工学学士 软件工程

⚙️ IT 技能

- 曾在华为（华为云深度学习平台、华为诺亚方舟实验室）和百度凤巢 CTR 模型组工作，4 年推荐广告模型和大规模深度学习平台研发经验，熟悉 TensorFlow 和 Paddle 等深度学习引擎，优化多个 Paddle Op，为 TensorFlow 贡献过 3 个 [patches](#)。
- 寻求对标阿里 P7 相关岗位（当前薪酬已在区间内）。

👨‍💻 项目经历

百度凤巢 CTR 模型中台 2020.6 – 至今

C++, Python, CUDA, NCCL, Paddle etc. 研发工程师

负责 AIBox/PaddleBox 训练框架开发与多个业务的支撑。PaddleBox 是基于 SSD/MEM/GPU 的异构参数服务器训练框架，通过软硬件联合优化来支撑万亿参数 DNN 模型的 Online Learning，目前支撑了百度商业化搜索广告、信息流原生广告等数十个场景的 CTR 模型训练。个人获得[百度移动生态部 MEG 最佳新人奖](#)、联合团队获得[百度技术委员会技术创新奖](#)，作为作者之一（团队内部排第三）将项目成果 «Communication-Efficient TeraByte-Scale Model Training Framework for Online Advertising» 投稿 VLDB。

- 训练框架开发
 - 性能优化。通过 Op Fusion 等技术优化多个 Paddle GPU Op (e.g. [fused embedding](#)、[continue value](#) 使得 DNN 训练整体提升 15%)，引入类似 Horovod 的 Tensor Fusion 技术优化梯度通信 (性能提升 5%)，DNN 训练性能累计提升超过 20%。
 - Embedding 量化。通过 Embedding 量化来优化存储和计算性能，与搜索广告主 CTR 模型合作把 Embedding 从 8 维扩展到 16 维提高模型表征能力而参数存储空间不变 (FP32->INT16)，CPM 提升超过 1%。[Paddle 代码](#)
 - 其他特性开发。参数服务器统一显存管理；Sparse 参数 Adam GPU 优化器，支撑 TDM 召回解决方案；Dense 模型转换等相关工具开发。
- 分布式 SSD 参数服务器架构升级
 - 项目背景。PaddleBox 架构为单进程架构，GPU Worker 和异构参数服务器位于同一进程空间内，其中 SSD KV 引擎存储全量模型，SSD 参数查找是很多场景模型训练的瓶颈。
 - 方案设计与开发。设计 SSD 参数服务器独立架构，支持 GPU Worker 和 SSD 参数服务器 M:N。架构升级涉及 SSD 参数查找和更新、模型加载、全量模型保存和增量模型保存等功能开发，通过多种方式优化 SSD-PS PULL 性能达到超线性加速比。
 - 项目收益。分布式 SSD 参数服务器 PULL 的性能可以达超线性加速比，通过调配 GPU Worker 和 SSD 参数服务器数量，灵活应对算力瓶颈和参数拉取瓶颈。架构升级后，搜索广告主模型内存占用从单进程的 1.2T 降到 700G（机器内存 1.5TB），可通过[模型混部](#)进一步提高资源利用率（进行中）。
- 分布式 GPU 参数服务器
 - 项目背景。分布式训练需要通过 RPC 预取分布在所有节点的 Embedding 参数，训练时直接从本机 GPU Hashtable 读取，不同机器 GPU 参数存储有冗余导致显存利用率不高。
 - 方案设计与开发。设计 GPU 多对多架构通信架构，通过参数存储无冗余的分布式 GPU Hashtable 方案来减少 GPU 显存占用，通过多种方式优化 Embedding 参数跨机跨卡访存性能。

- 项目收益。HBM PS 显存占用显著减少，约为原来的 1/N (N 为节点数)，可以支撑更大 DNN 模型。

业务推广

- 商业化垂类业务支撑。支撑贴吧等业务从基于 MPI 的 CPU 参数服务器框架迁移到 PaddleBox。
- 商业化反作弊业务支撑。支撑多个业务从 XGBoost 树模型转到 PaddleBox DNN 模型，开发以连续特征为主、离散特征为辅的 DNN 模型。

华为 - 共两次晋升 诺亚方舟实验室

2018 年 9 月-2020 年 6 月

Tensorflow, Hive, Spark etc. 高级推荐算法工程师

华为手机应用市场（亿级月活产品）App 付费推广业务。参与 Offline、Nearline 和 Online 三层推荐架构开发，历经 FTRL、FFM 和 DNN 类模型的迭代优化，从数据、特征、模型和系统层面端到端优化提升业务指标。

- 数据和特征层面。采样策略探索，线上线下特征一致化；挖掘 Item、User、Context 单特征和组合特征，debias 建模。
- 模型层面。历经 FTRL、FFM 和 Wide&Deep 类模型迭代优化，探索 CTR、CVR 联合建模，多榜单联合建模，eCPM 累计提升超过 15%。
- 系统层面。
 - 训练优化。基于 OpenMP 的 FTRL 训练优化，支撑单机百亿样本小时级训练；深度学习训练优化，构建 Spark 生成 TFRecord Pipeline，优化深度学习数据读取模块，落地多卡训练，单机四卡训练线性加速比 0.7。数据 IO 优化方案现用于[华为自研深度学习框架 mindspore ModelZoo](#)。
 - 线上服务优化。Java 线上服务开发，利用 TF Batching 机制推理性能优化，推理性能提升 40%。
 - 分布式推理探索。分布式 TensorFlow-Serving 推理原型开发验证（多模型副本），高并发情况下 1000+ 候选集预测线性加速比 0.77。Demo

原生广告业务

- 智能助手原生广告。负责智能助手业务（信息流广告）数据、特征和模型的端到端优化，引入文本和图片多模态特征，上线初版 FTRL 模型和 DCN 模型，CTR 点击率提升累计超过 20%，eCPM 提升超过 15%。

推荐多样性算法研究与落地

- 算法研究。提出一种个性化的 DPP 算法 (Determinantal Point Processes, 行列式点过程)，在不影响精度的情况下提升推荐多样性。研究成果[Personalized Re-ranking for Improving Diversity in Live Recommender Systems](#)中稿 KDD Workshop(DLP-KDD 2020)，第二作者。
- 应用市场猜你喜欢场景业务落地。负责整体方案设计，线上服务代码开发与测试，其中原始 DPP 下载转化率较基线提升 5.5%，提出的个性化 DPP 下载转化率较基线提升 6.5%。

华为 ModelArts 深度学习云服务（从零到一，九个月晋升）

2017 年 7 月-2018 年 9 月

Java, Docker, Kubernetes, Tensorflow etc. 深度学习云平台后端开发

服务端组件

- 组件功能开发。负责训练作业和预置算法模型库等模块的设计与开发，支持 TensorFlow、MXNet、PyTorch 和 Horovod 等深度学习作业的生命周期管理，支持多种深度学习引擎、多种版本模型库。
- 服务可靠性。对接公有云统一告警服务、调用链监控服务、云审计和日志收集服务，无状态多实例容器化部署。

作业调度组件

- 组件功能开发。参与基于 Kubernetes 的深度学习作业调度和监控组件设计与开发，实现对多引擎、多类型深度学习作业的全生命周期管理，负责部分 gPRC 后端接口的实现，对外提供 gPRC 服务。

消息 (HTTP/gRPC) 转发组件

- 组件功能开发。负责技术选型，对接作业调度组件和文件管理组件 gRPC 服务，向外提供 RESTful API。
- 服务可靠性。Server-Side、Client-Side 对 SSL 的支持，数据库定时心跳检测，作业状态上报失败重试。

其它相关工作

- 开源贡献。TensorFlow 对 AWS S3 文件系统的支持 (重构/BUG FIX/UT)，贡献 3 个 patches(C++)。
- MXNet NCCL/RDMA 高性能技术调研和性能测试。